UNIVERSIDAD INDUSTRIAL DE SANTANDER.
ESCUELA DE MATEMÁTICAS. BUCARAMANGA
Profesor: Andrés Ríos-Gutiérrez
ESTADÍSTICA II

TAREA 2:

MODELOS DE REGRESIÓN EN LENGUAJE `Python`:

Mire los vídeos subidos a Youtube:
https://www.youtube.com/watch?v=9kJIRrbQFlE&t=1s
https://www.youtube.com/watch?v=0RvRcDCmP4o&t=1s

Usando lenguaje `Python` (se recomienda usar `Google Colaboratory`), cargue la base de datos `SB11_20231.TXT`, la cual corresponde a las estadísticas del ICFES de la segunda cohorte (para más información se puede consultar https://www.icfes.gov.co/saber-al-detalle/#:~:text=Saber%20al%20detalle.%20Serie%20de%20publicaciones) utilizando las siguientes líneas de código:

```
from google.colab import files # Para cargar archivos en google colab
uploaded = files.upload()
import pandas as pd
import io
datos_icfes = pd.read_csv(io.BytesIO(uploaded['SB11_20231.TXT']),
                                     delimiter='¬')
```

Elabore un cuaderno en `Jupyter` y cárguelo a una rama del `Github` personal donde se muestren los resultados y las interpretaciones línea a línea de los siguientes ítems:

- **Eliminación de valores faltantes** en el análisis estadístico. Para ello puede implementar los algoritmos sobre el elemento `icfes_sin_nan` generado por la siguiente línea de código:

```
icfes_sin_nan =
datos_icfes[(~datos_icfes['ESTU_INSE_INDIVIDUAL'].isna()) &
 (~datos_icfes['PUNT_LECTURA_CRITICA'].isna()) &
   (~datos_icfes['PUNT_MATEMATICAS'].isna()) &
    (~datos_icfes['PUNT_C_NATURALES'].isna()) &
     (~datos_icfes['PUNT_SOCIALES_CIUDADANAS'].isna()) &
      (~datos_icfes['PUNT_INGLES'].isna())]
```

- **Selección de variables explicativas a partir de los diagramas de dispersión** entre la variable respuesta y una a una de las variables explicativas
- **Selección de variables explicativas a partir de los coeficientes de correlación** de Pearson de Kendall y de Spearman
- **Selección de variables explicativas a partir del coeficiente de determinación calculados** a partir del **modelo de regresión lineal múltiple** con variable respuesta `'ESTU_INSE_INDIVIDUAL'` y con todas las variables explicativas `'PUNT_LECTURA_CRITICA'`, `'PUNT_MATEMATICAS'`, `'PUNT_C_NATURALES'`,

'PUNT_SOCIALES_CIUDADANAS' y 'PUNT_INGLES', salvo una de estas (la cual se quiere ver si es explicativa o no). Hacer este proceso con todas las variables explicativas.

- **Diagrama con el plano de dispersión** con variable respuesta 'ESTU_INSE_INDIVIDUAL' y con las dos variables más explicativas de acuerdo con el ítem anterior.

Una vez realizado el desarrollo anterior implemente los siguientes algoritmos con variable respuesta 'ESTU_INSE_INDIVIDUAL' y con las variables explicativas seleccionadas de 'PUNT_LECTURA_CRITICA', 'PUNT_MATEMATICAS', 'PUNT_C_NATURALES', 'PUNT_SOCIALES_CIUDADANAS' y 'PUNT_INGLES'. Para ello tome un conjunto de datos de entrenamiento del 80% utilizando la función train_test_split, a partir del elemento sin datos faltantes (puede ser el elemento icfes_sin_nan)

1. Un **modelo de regresión lineal múltiple**.
2. Un **modelo de red neuronal de perceptrón multicapa** con variable respuesta 'ESTU_INSE_INDIVIDUAL' y variables explicativas 'PUNT_LECTURA_CRITICA', 'PUNT_MATEMATICAS', 'PUNT_C_NATURALES', 'PUNT_SOCIALES_CIUDADANAS' y 'PUNT_INGLES', bajo los argumentos especificados en la siguiente línea de código:

```
red = MLPRegressor(hidden_layer_sizes=(100,100,100,100, 100, 100),
                                        max_iter = 500,
                                        activation = 'relu',
                                        solver = 'adam',
                                        learning_rate = 'invscaling')
```

Haga la imputación utilizando el modelo con el mejor ajuste de los datos de la variable 'ESTU_INSE_INDIVIDUAL' (nivel socioeconómico del evaluado) para la cual se tienen los datos de las variables explicativas 'PUNT_LECTURA_CRITICA', 'PUNT_MATEMATICAS', 'PUNT_C_NATURALES', 'PUNT_SOCIALES_CIUDADANAS' y 'PUNT_INGLES', es decir, haga la imputación para el elemento icfes_connan generado por:

```
icfes_connan =
datos_icfes[(datos_icfes['ESTU_INSE_INDIVIDUAL'].isna()) &
 (~datos_icfes['PUNT_LECTURA_CRITICA'].isna()) &
   (~datos_icfes['PUNT_MATEMATICAS'].isna()) &
    (~datos_icfes['PUNT_C_NATURALES'].isna()) &
     (~datos_icfes['PUNT_SOCIALES_CIUDADANAS'].isna()) &
      (~datos_icfes['PUNT_INGLES'].isna())]
```

Realice predicciones de interés, por ejemplo, tome aquellos estudiantes que un desempeño sobresaliente en lectura crítica y bajo puntaje de inglés.

Establezca comparaciones con los puntajes de corte de admisión de la UIS para las carreras de interés ¿qué perfil tienen los admitidos a estos programas?

La malla de calificación del informe es el siguiente:

	Máximo:
Presentación: Explicación clara y concisa, ortografía, uso de gráficos estadísticos con buena resolución en el documento, buena redacción, no escribir dos veces la misma idea, ni 'carreta'.	15
Profundidad estadística: Uso de las herramientas estadísticas de los procedimientos, explicación clara de los resultados estadísticos, uso adecuado de los algoritmos, búsqueda y comparación con otras metodologías estadísticas. Resultados y análisis de resultados (desde la estadística). Revisión tanto de argumentos como de parámetros e hiperparámetros para un mejor ajuste de los modelos implementados. Búsqueda de soluciones optimas y precisas.	20
Contexto: Formulación de análisis de resultados y conclusiones con respecto al contexto de los datos. Justificación detallada de la limpieza de datos (datos no representativos, valores faltantes) de acuerdo con literatura del contexto de los datos. Introducción, análisis de resultados y conclusiones (desde el contexto de los datos). Explicación detallada de la base de datos y cómo se obtuvieron o tomaron los datos	15